ANEXO 6: Marco de Riesgos, Límites Operacionales y Gobernanza

Este anexo detalla de manera rigurosa y técnica los riesgos intrínsecos al sistema, los límites ético-operacionales (Líneas Rojas) y los mecanismos de gobernanza implementados para asegurar el cumplimiento regulatorio y la equidad (*fairness*) del sistema de IA, clasificado como de alto riesgo bajo la Ley de Inteligencia Artificial de la UE (AI Act).

1. Gestión de Riesgos Críticos y Estrategias de Mitigación

Se han identificado y formalizado tres vectores de riesgo primarios que impactan directamente la seguridad y la fiabilidad del modelo.

Riesgos Críticos

- **Sesgo de Datos Históricos:** El modelo podría perpetuar la criminalización o estigmatización de zonas basada en patrones del pasado , afectando la *Equal Performance Across Groups*.
    - **Mitigación: Diversificación y Enriquecimiento de Datos:** Ampliación de la diversidad y la frecuencia de actualización de las fuentes. Uso de nuevas fuentes (luminosidad, horario comercial, etc.) y aumento del intervalo temporal para el reentrenamiento.
- **Uso por Delincuentes (Riesgo de Adaptación):** Explotación del sistema por actores maliciosos para anticipar rutas recomendadas y emboscar a usuarios.
    - **Mitigación: Aleatoriedad Contextual y Protección del Modelo:** Combinación de coeficientes de seguridad con una **pequeña aleatoriedad contextual** en la construcción final de la ruta, garantizando la cobertura distribucional. El modelo se protege marcando una zona como peligrosa si existe un testigo (tiempo real).
- **Predicción Errónea (Falsos Negativos):** Clasificación catastrófica de una zona peligrosa como segura , comprometiendo directamente la seguridad física del usuario.
    - **Mitigación: Penalización Asimétrica y Reentrenamiento Continuo:** Penalización asimétrica de los falsos negativos durante el entrenamiento. **Reentrenamiento continuo** del modelo y uso de reportes de usuarios como **mecanismo de *feedback*** para corrección inmediata.

1.1. Fiabilidad de Reportes y Precisión Temporal

- **Gestión de Falsos Negativos:** Se implementa una **penalización asimétrica** en la función de coste del modelo, dando mayor peso al error de clasificación peligrosa/segura. Una calle con alta recurrencia de reportes verá su coeficiente de seguridad reducido **proporcionalmente** al número de reportes.

- **Fiabilidad de Reportes:** La primera barrera es la **autenticación** por email o teléfono. Se desarrollarán **redes neuronales específicas** para la detección de patrones anormales o fraudulentos. A los usuarios con reportes valiosos y fiables se les asignará un **mayor peso** en el cálculo del riesgo.
- **Precisión Temporal:** La precisión en tiempo real se garantiza complementando los datos oficiales trimestrales con **reportes de usuarios** , el uso de **procesos de *clustering*** para la extrapolación de datos a zonas desconocidas , y la expectativa de acuerdos para acceder a **denuncias en comisarías**.

2. Límites Operacionales y Éticos (Líneas Rojas)

La implementación de estas directrices es obligatoria para mantener la clasificación de alto riesgo.

- **Protección de Datos / RGPD:** No guardar datos personales de forma explícita; usar exclusivamente **técnicas de anonimizado** (ej., *hashing* de identidad). Los empleados no deben poder acceder a información identificable del usuario.
- **Finalidad y Uso de Datos:** No usar datos para fines distintos a la seguridad o navegación. No vender información de las zonas que visita el usuario.
- **Integridad del Sistema:** No desplegar un modelo de **caja negra** total o un modelo que haya fallado la auditoría de sesgos. No depender de una única fuente de información.
- **Uso de Localización:** No usar la geolocalización del usuario cuando la aplicación no está siendo utilizada activamente.
- **Restricción de Edad:** No permitir el uso de la aplicación a menores de 14 años.

3. Marco de Gobernanza, Rendición de Cuentas y Transparencia

3.1. Separación Funcional y Poder de Veto

El proyecto garantiza una **gobernanza robusta** mediante la separación estricta de responsabilidades:

- **Separación Funcional:** Existe una división estricta entre el desarrollo comercial (*Product Owner*) y la **supervisión ética** (*Comité Ético*).
- **Poder de Veto Vinculante:** El **Comité Ético** posee un **poder de veto legal vinculante** sobre las decisiones de despliegue y operación.
- **Imperativo de Negocio:** Mantener esta independencia es un imperativo de negocio, ya que cualquier sesgo corporativo resultaría en la pérdida de confianza y colaboración de la comunidad.

3.2. Mecanismo de Parada de Emergencia

El protocolo de desactivación inmediata es crucial para un sistema de alto riesgo.

- **Activación:** El mecanismo puede ser activado por el **Product Owner** con el respaldo del Comité Ético.
- **Disparadores (*Triggers*):** Se activa ante un **fallo grave** que resulte en rutas con riesgo excesivamente alto , ante **pérdida de control** o evidencia de manipulación masiva (ej., ataque de *bots* exitoso), o una violación crítica del RGPD o brecha de seguridad.
- **Ejecución:** Desconexión del **motor de IA central** o suspensión de la recomendación segura, dejando operativa únicamente la **función de mapa básico** (sin IA).

3.3. Transparencia y Trazabilidad

- **Auditoría y Transparencia:** El sistema se someterá a **auditorías externas bianuales y públicas** para verificar su independencia, manejo de datos y uso ético.
- **Trazabilidad y Explicabilidad (XAI):** Se implementarán métodos de explicabilidad (*XAI*) como **SHAP** para mejorar la comprensión de las predicciones de la red neuronal. Se guardan **todas las versiones del modelo** para permitir la auditoría de errores en cualquier intervalo temporal.
- **Rendición de Cuentas:** Se mantienen canales de reclamación y soporte con un tiempo de respuesta comprometido de **15 días hábiles**.