ANEXO 2: Datos y Entrenamiento del sistema

Este anexo detalla las fuentes de datos utilizadas, los criterios de calidad implementados para su validación, y la estimación de los recursos computacionales y el impacto ambiental derivados del entrenamiento del modelo.

1. Tipos de Datos Utilizados y Funcionalidad

El modelo **Neural Network Regressor** de GPS-Safe se entrena y actualiza mediante la combinación de las siguientes fuentes de información:

- **Datos Públicos Oficiales:** Constituyen la base institucional y estandarizada del sistema. Incluyen estadísticas de criminalidad agregadas (homicidios, robos, agresiones sexuales, etc.) publicadas trimestralmente por el Ministerio del Interior.
- **Noticias de Medios de Comunicación:** Se analizan artículos de fuentes como *eldiario.es* y *20minutos.es* para complementar la baja frecuencia de los datos oficiales. Esta fuente es una medida de mitigación clave contra el "Sesgo de Datos Históricos", pues aporta una visión más actual y diversificada.
- **Reportes Voluntarios Ciudadanos:** Son el pilar comunitario del sistema. Los usuarios reportan incidentes (robos, acoso, zonas mal iluminadas), aportando una capa fundamental de inteligencia colectiva en tiempo real.
- **Datos Contextuales y del Usuario:** Se integran APIs de tráfico y meteorología. Adicionalmente, los usuarios pueden compartir datos opcionales de salud, siempre con consentimiento explícito.
- **Proxies Ambientales:** Se espera que para 2029 sea posible el uso de estos *proxies* para mejorar los datos en tiempo real.

2. Origen, Criterios de Calidad y Criterios Legales

Los datos que alimentan el modelo se seleccionan para garantizar su fiabilidad, diversidad y actualización.

Origen de los Datasets

- **Ministerio del Interior:** La base de estadísticas oficiales de criminalidad tiene licencia de uso público. Su periodicidad trimestral asegura consistencia y estandarización, aunque necesita ser complementada con fuentes más frecuentes.
- **Medios de Comunicación:** Se extraen únicamente los hechos reportados para complementar los datos oficiales, sin reproducir textos completos ni infringir propiedad intelectual. Para fines legales y comerciales, la empresa debe obtener licencia de uso directamente de los medios o mediante agregadores.
- **Reportes Ciudadanos:** Aportan información en tiempo real que complementa los datos históricos. La fiabilidad se mantiene mediante un análisis automático de coherencia y limitando la frecuencia de envío diario para evitar reportes falsos o repetidos.

Criterios Mínimos de Calidad

Para que los datos sean considerados válidos, deben cumplir con:

- **Precisión Geográfica:** Cada dato debe estar localizado al menos a nivel de municipio, lo que asegura que los coeficientes de riesgo sean precisos y relevantes.
- **Actualización Frecuente:** Mientras que los datos oficiales son trimestrales, los hechos extraídos de noticias y los reportes ciudadanos permiten mantener una actualización diaria del sistema.
- **Diversidad de Fuentes:** La combinación de datos oficiales, medios y reportes ciudadanos reduce los sesgos históricos al evitar la dependencia de una única fuente.
- **Control de Falsos Positivos:** Todos los datos se someten a filtros de coherencia y análisis de patrones sospechosos para evitar que información maliciosa o errónea afecte las recomendaciones.

3. Impacto Ambiental y Estimación de Recursos de Entrenamiento

El sistema fue diseñado buscando la eficiencia computacional para minimizar su huella de carbono.

- **Hardware:** El desarrollo se realiza utilizando una GPU **NVIDIA H100**, que permite el procesamiento rápido de modelos complejos.
- **Coste de Desarrollo:** Se estiman **50 ciclos** de desarrollo completos para pruebas y ajustes.
- **Estimación Financiera y Ambiental:** El coste total en servicios *cloud* (AWS) para los 50 ciclos puede alcanzar hasta **4.580 €**. La huella de carbono generada durante todo el proceso se estima en hasta **140 kg de CO_2**