ANEXO 3: Evaluación y métricas

El sistema GPS-Safe se evalúa exhaustivamente para garantizar la precisión del **coeficiente de seguridad** de cada zona, reflejando el nivel de riesgo ponderado por la gravedad y frecuencia de delitos y reportes. La correcta integración de todas las fuentes de datos (estadísticas oficiales, reportes ciudadanos, tráfico, meteorología y variables contextuales) es fundamental para asegurar que las rutas sean seguras y coherentes con la realidad, verificando que el modelo funcione de manera confiable, ética y consistente antes de su despliegue.

1. Ejes Clave de la Evaluación del Modelo

La evaluación del sistema se centra en aspectos críticos del funcionamiento del modelo:

- **Integración de Datos:** Se verifica que los distintos tipos de datos se combinen correctamente para generar predicciones coherentes y sólidas.
- **Precisión y Minimización de Errores Críticos:** El objetivo es asegurar una precisión superior al 95% y minimizar los **falsos negativos** (clasificación de zonas peligrosas como seguras), ya que estos representan fallos críticos que comprometen la seguridad del usuario.
- **Interpretabilidad (XAI):** Se garantiza que el modelo sea **explicable**, evitando que funcione como una "caja negra". Esto permite que sus decisiones puedan entenderse, revisarse y justificarse por el equipo de desarrollo y el Comité Ético.

2. Métricas Técnicas Utilizadas para la Calidad de la Predicción

Para evaluar la calidad de las predicciones del coeficiente de seguridad, se emplean métricas estándar de regresión y clasificación, cubriendo diferentes aspectos del rendimiento y seguridad del modelo:

- **MAE (*Mean Absolute Error*):** Mide el error medio de las predicciones, proporcionando una visión general de la precisión del modelo.
- **MSE (*Mean Squared Error*):** Penaliza más los errores grandes, lo que es esencial para identificar predicciones que se desvían significativamente de los valores reales y que podrían indicar un riesgo no capturado.
- **Maximum Absolute Error:** Detecta los errores individuales más críticos, asegurando que ninguna predicción produzca un riesgo inaceptable o catastrófico.
- **F1-Score:** Aplicado a la clasificación de zonas en peligrosas o seguras, combina precisión y exhaustividad para equilibrar la capacidad del modelo de detectar zonas de riesgo sin marcar incorrectamente zonas seguras.

3. Umbrales Críticos "Go/No-Go" para Producción

El despliegue del modelo GPS-Safe está condicionado al cumplimiento simultáneo de las siguientes condiciones críticas, asegurando la fiabilidad y la responsabilidad ética:

1. **Precisión Superior al 95%:** El modelo solo se desplegará si alcanza una precisión mayor al 95% en la predicción del riesgo de cada zona. Esto garantiza que la gran mayoría de las recomendaciones sean confiables.
2. **Tasa de Falsos Negativos por Debajo del 1%:** Clasificar una zona peligrosa como “segura” se considera un **fallo crítico** que impide el despliegue. Aunque se reconoce la inviabilidad tecnológica de una tasa nula, este límite estricto se establece para asegurar que los fallos que comprometen la seguridad sean excepcionales.
3. **Validación del Comité Ético:** El modelo debe superar la auditoría del Comité Ético antes de su despliegue, certificando que el sistema es **interpretable** (XAI) y **comprensible**. Esta validación asegura que las decisiones del modelo no estén sesgadas y puedan ser justificadas en cualquier momento.
4. El sistema optimiza el **Recall** sobre la **Precisión**. Priorizamos marcar una zona segura como 'Precaución' (**falso positivo**) antes que dejar una zona peligrosa sin marcar (**falso negativo**). El sistema no garantiza seguridad absoluta, sino que ofrece una **estratificación de riesgo (Bajo, Medio, Alto, Desconocido)** basada en la información disponible.