ANEXO 7: Usuarios, sesgos y colectivos afectados

Este anexo detalla el impacto potencial del sistema de IA en diversos colectivos, los sesgos inherentes a las fuentes de datos, y los compromisos de diseño y métricas implementados para garantizar la equidad y mitigar la discriminación.

1. Colectivos en Situación de Vulnerabilidad y Degradación del Rendimiento

El sistema puede experimentar una degradación en el rendimiento de las recomendaciones para varios grupos de usuarios, especialmente aquellos cuya experiencia no está completamente representada en los datos de entrenamiento.

- **Residentes de Zonas con Escasez de Datos Históricos:** Las predicciones en estas áreas serán inherentemente menos precisas, a pesar del uso de técnicas de *clustering* para la extrapolación de características.
- **Turistas:** Debido a la utilización de zonas agregadas y noticias locales, el rendimiento del sistema puede disminuir si se usa en espacios turísticos, potencialmente debido a sesgos específicos introducidos durante el entrenamiento del modelo.
- **Usuarios con Conectividad Inestable:** Aquellos usuarios sin una conexión de red estable no podrán acceder a los reportes de incidentes en tiempo real, lo que compromete la actualidad de su coeficiente de riesgo.
- **Personas Acompañadas de Menores:** La aplicación basa sus rutas en los datos del usuario principal y no considera las necesidades o variables de seguridad de los acompañantes menores, lo que puede resultar en rutas inadecuadas.
- **Usuarios de Transporte Público:** La complejidad y variedad del ambiente de personas en el transporte público hacen que el sistema no rinda de manera óptima en estos escenarios.

2. Identificación y Consecuencias de los Sesgos del Modelo

Se han identificado sesgos intrínsecos al sistema que requieren mitigación activa:

- **Sesgo de Vigilancia:** Las zonas con mayor presencia policial tienden a generar más reportes de incidentes, lo que artificialmente las hace parecer más peligrosas. Por el contrario, las zonas con menos vigilancia pueden parecer más seguras de lo que realmente son.
- **Sesgo de Peligro Relativo:** Un barrio puede ser clasificado como seguro si sus indicadores de riesgo son bajos en comparación con el conjunto de datos global, aunque el riesgo en términos absolutos siga siendo significativo para el usuario.
- **Bucle de Retroalimentación (*Feedback Loop*):** El riesgo más crítico es que, al desviar sistemáticamente a los "peatones buenos" por las mismas rutas seguras, las

calles consideradas inseguras se aíslen y marginalicen aún más, intensificando la formación de guetos y perjudicando a los residentes de esas áreas.
- **Fuentes de Sesgo:** Los sesgos provienen principalmente de dos fuentes: las noticias (que pueden contener tendencias políticas) y los reportes voluntarios de usuarios. Los reportes discriminatorios son gestionados mediante la baja de la cuenta del usuario. Añadiendo a este en una lista negra.

3. Compromisos de Diseño a Favor de la Equidad

El proyecto implementa mecanismos técnicos y de gobernanza para mitigar los sesgos identificados:

- **Aleatoriedad Controlada:** Se utilizan mecanismos para introducir una pequeña aleatoriedad cuando existen alternativas con niveles de seguridad similares, evitando así la desviación y penalización constante de las mismas rutas.
- **Reciclaje de Zonas:** El coeficiente de riesgo de una zona disminuye con el tiempo si no se registran nuevos incidentes. Esto evita que una zona permanezca marcada como peligrosa de forma indefinida.
- **Normalización por Densidad Poblacional:** El algoritmo no utiliza el número absoluto de crímenes, sino la tasa relativa ajustada a la densidad de tránsito peatonal y población en el momento. Esto ayuda a penalizar menos las zonas turísticas o de alta afluencia.
- **Supervisión Continua del Comité Ético:** El Comité tiene el mandato explícito de auditar el modelo en busca de sesgos y supervisar su impacto en los distintos colectivos, con poder para exigir correcciones.

4. Métricas de Equidad (*Fairness*) y Mínimos Autoimpuestos

Métricas de Evaluación

El Comité Ético utiliza métricas específicas para auditar la equidad del modelo:

- ***Equal Performance Across Groups*:** Compara si la precisión de las recomendaciones (riesgo real vs riesgo predicho) se mantiene similar entre zonas y poblaciones distintas.
- ***False Positive / False Negative Balance*:** Se utiliza para determinar si el modelo sobreestima el coeficiente de riesgo en algunos barrios o lo subestima en otros. Todo mediante umbrales de aceptación de riesgo.
- ***Distributional Coverage*:** Asegura que las rutas recomendadas cubran razonablemente toda la ciudad y no solo se concentren en los barrios con más datos o más reportes.

Mínimos Autoimpuestos para la Transparencia

- **Transparencia:** Explicar al usuario qué datos específicos se utilizan para calcular la ruta recomendada.
- **Revisión Humana Periódica:** Realizar auditorías internas regulares para la detección activa de sesgos en rutas o en los datos de entrada.
- **Control de Calidad de Datos:** Depurar datos ruidosos, incompletos o asociados a prejuicios (como reportes subjetivos sin validación sistemática).
- **Mecanismo de Retroalimentación:** Permitir que los usuarios reporten rutas que consideren mal clasificadas y revisar estos reportes de forma sistemática.