GPS-Safe

Cuando la seguridad no es un privilegio, sino una elección.

Date: 08/12/2025
Version: 1.0.0
Developed By: Mario Baldocchi, Pablo M. Rodríguez, Carlota Salazar, Artem Vartanov, Yushan Yang
Model Type: Neural Network Regressor
License Code: GPL
License Model: Proprietary
GitHub Repository: https://github.com/EthicsAI-UCM/GPS-Safe

Resumen del modelo y del proyecto

La seguridad física en nuestros desplazamientos urbanos es un derecho fundamental que se ve constantemente amenazado por la falta de información contextualizada y predictiva. Los usuarios a menudo pueden escoger la rapidez al planificar sus rutas, pero carecen de herramientas que les permitan también escoger la seguridad.

GPS-Safe es una **aplicación de navegación** inteligente diseñada para guiar a los usuarios a casa por la **ruta más rápida y, sobre todo, más segura**. Emplea un modelo de IA para la predicción de coeficientes de riesgo de cada zona, que se utilizan posteriormente para construir la ruta óptima en tiempo real. Actúa como un asistente preventivo que integra datos de diversas fuentes gubernamentales, periodísticas y de los usuarios.

La innovación de GPS-Safe es ofrecer rutas seguras de forma activa, a diferencia de otras tecnologías como Citizen (citizen.com), que solo proporciona reportes reactivos de incidente.

Usos

El propósito principal de GPS-Safe es ofrecer rutas priorizando la seguridad del usuario.

Usuarios previstos

Este software está orientado a los siguientes perfiles de usuarios:

- **Turistas:** Personas que no conocen del todo bien la ciudad y no quieren poner en riesgo su seguridad.
- **Conductores y peatones:** Personas que desean evitar zonas con un historial de incidentes o con factores de riesgo contextuales.
- **Personas con movilidad reducida:** El sistema ofrece rutas personalizadas que tienen en cuenta barreras arquitectónicas y datos de accesibilidad para garantizar un trayecto seguro y viable.

Casos de uso previstos (intended usage)

La aplicación se ha desarrollado explícitamente para su uso como un navegador que calcula las rutas seguras y rápidas, teniendo en cuenta coeficientes de riesgo de las zonas actualizados al día. Además, se puede usar para entender el coeficiente de riesgo de una zona, te proporciona una justificación usando noticias, reportes y estadísticas de criminalidad.

Casos de uso no previstos (mal-usos, out-of-scope)

Para evitar situaciones de malentendido de para qué se puede usar la aplicación, se ha formalizado en el Anexo que, entre otros, no dejamos usar la app para saber rutas de otras personas, ni manipular los coeficientes de riesgo usando reportes falsos. La app nunca se debe usar para fines criminales, violencia ni transmisión de desinformación.

Datos y entrenamiento

Tipos de datos utilizados

El modelo se entrena y actualiza utilizando una combinación de las siguientes fuentes:

I. **Datos públicos oficiales:** Esta es la base, porque son datos institucionales y estandarizados.
II. **Noticias de medios de comunicación:** Esta es una medida de mitigación clave contra el "Sesgo de Datos Históricos" (ver Sección 7), pues aporta una visión más actual y diversificada.
III. **Reportes voluntarios ciudadanos dentro de la app:** Constituyen el pilar comunitario del sistema.
IV. **Datos contextuales y del usuario:** Integramos APIs de tráfico y meteorología.
V. **Proxies Ambientales:** Para mejorar los datos en tiempo real.

Recursos de entrenamiento y su impacto ambiental

Hemos diseñado el sistema para un entrenamiento eficiente. El desarrollo se realiza utilizando una GPU `NVIDIA H100`. Para 50 ciclos de desarrollo completos, se estima un coste en servicios cloud (AWS) de hasta **4.580 €** y una huella de carbono asociada de hasta **140 kg de CO_2**.

Evaluación y métricas

El sistema se evalúa por su capacidad para calcular correctamente el **coeficiente de seguridad** de cada zona. Se mide con **MAE, MSE y Maximum Absolute Error** para controlar desviaciones y errores críticos, y con **F1-Score** para equilibrar precisión y exhaustividad en la clasificación de zonas.

Umbrales "go/no-go" para producción

El modelo será apto para despliegue solo si cumple simultáneamente: **Precisión superior al 95%**, **Falsos Negativos inferiores al 1%** (priorizando siempre el **Falso Positivo** sobre el **Falso Negativo**), y la aprobación de la auditoría del Comité Ético que garantice su interpretabilidad y ausencia de sesgos.

Como parte de este proceso, se comprobará explícitamente que el modelo no degrada su rendimiento para colectivos en situación de vulnerabilidad (se detalla en la Sección 8).

Privacidad y protección de datos

De acuerdo con la Ley de Inteligencia Artificial de la UE (AI Act), GPS-Safe se clasifica como un sistema de IA de **alto riesgo** debido a su impacto directo en la seguridad física de las personas, lo que exige las más altas exigencias de control, transparencia y supervisión. El sistema está diseñado para el estricto cumplimiento del RGPD y la LOPD-GDD, basándose en **cuatro pilares**: el uso de datos requiere base legal mediante consentimiento explícito , minimización de datos recogiendo solo lo necesario , uso limitado de la información únicamente para calcular rutas y mejorar la seguridad , y garantizar los derechos del usuario a acceder, modificar o borrar sus datos desde la aplicación.

Medidas de protección destacadas

Además del cumplimiento normativo, se han implementado tres medidas de protección avanzadas:

I. **Anonimizado de identidad al generar reportes**: se usa un hash en vez del DNI o Nombre al crear un reporte.
II. **Envío de la ubicación encriptada del usuario**: se usa un sistema de codificación de la ubicación end-to-end que se encripta y desencripta de forma rápida, de modo que terceros no pueden conocer la ubicación real.

III. **Frase secreta y 2FA**: Para iniciar sesión en un nuevo dispositivo, el usuario debe introducir la frase de su cuenta, reduciendo el riesgo de acceso no autorizado a datos sensibles. Además de usar también 2FA.
IV. **Privacidad diferencial**: Mediante la Privacidad Diferencial, el sistema agrega vectores de riesgo anonimizados para crear mapas de calor para la administración, garantizando que la reidentificación de trayectos individuales sea matemáticamente imposible.

Propiedad intelectual y modelo de apertura

Régimen de licencias

COMPONENTE	LICENCIA
Código de la aplicación	GPL
Modelo de IA y código de entrenamiento	Propietaria
Datos de reportes de usuarios	CC BY-NC
Datos de fuentes gubernamentales	CC0
Documentación del proyecto	CC BY-NC-SA

Modelo de negocio y sostenibilidad

El proyecto se financia mediante publicidad no invasiva, donaciones voluntarias, y mediante los datos generados por la alertas se venderían dashboards de Inteligencia Urbana a Ayuntamientos para mejorar iluminación o seguridad brindada por las FCSE. Esto nos ayuda a mantener costes operativos sin comprometer usuarios. En cuanto a los colaboradores, la empresa se compromete a:

I. Transparencia en el desarrollo, mediante la publicación del *roadmap* y el sistema de seguimiento de incidencias.
II. Reconocimiento, pues aquellos desarrolladores que contribuyan al proyecto serán incluidos en la documentación oficial.
III. Ambiente positivo, mediante la aplicación de un rígido código de conducta.

Riesgos, límites y gobernanza del sistema

Los tres riesgos más críticos son: el Sesgo de Datos Históricos, mitigado al ampliar la diversidad de datos ; el Uso por Delincuentes, mitigado mediante la combinación de coeficientes de seguridad y aleatoriedad contextual ; y la Predicción Errónea, mitigada por el reentrenamiento continuo y reportes de usuarios.

Líneas rojas

I. No guardar datos personales de forma explícita, usar técnicas de anonimizado de datos (incluso trabajadores de la empresa no pueden usar los datos para saber información sobre los usuarios).
II. No usar datos para fines distintos a la seguridad o a la navegación.
III. No usar la localización del usuario cuándo no está usando la app.
IV. No vender información de zonas que visita el usuario.
V. No usar una única fuente de información.
VI. No desplegar un modelo de caja negra o modelo sesgado.
VII. No permitir el uso de la app a menores de 14 años.

Parada de emergencia

¿Quién puede parar?

El Product Owner, con el respaldo del Comité Ético.

¿Cuándo?

- Fallo grave que derive en la recomendación de rutas con riesgo conocido o excesivamente alto.
- Pérdida de control o evidencia de manipulación masiva (p. ej., ataque de bots exitoso).
- Detección de una violación crítica del RGPD o una brecha de seguridad que afecte a los datos sensibles de los usuarios.

¿Cómo?

Desconexión del motor de IA central o la suspensión temporal de la funcionalidad de recomendación de rutas seguras, dejando activa únicamente la función de mapa básico (similar a un mapa sin IA).

Rendición de cuentas

El sistema ofrece canales de reclamación y soporte en 15 días hábiles, mientras el Comité Ético audita continuamente riesgos y supervisa el cumplimiento de los principios.

Usuarios, sesgos y colectivos afectados

Colectivos en situación de vulnerabilidad

El sistema puede tener un **rendimiento degradado** para varios colectivos vulnerables. Las predicciones son **menos precisas** para **residentes** de zonas con pocos datos y para **turistas** debido a sesgos. Los **usuarios con poca conexión** no verán reportes en tiempo real , y las rutas podrían no ajustarse a las necesidades de **personas acompañadas de menores** o **usuarios de transporte público**.

En caso de pertenecer a más de un colectivo, la experiencia puede resultar no del todo satisfactoria.

Sesgos

Los sesgos críticos incluyen el Sesgo de Vigilancia, donde las zonas más patrulladas parecen más peligrosas por la cantidad de reportes, y el Sesgo de Peligro Relativo. Además, existe el riesgo de un Bucle de Retroalimentación que podría marginalizar calles ya consideradas inseguras al desviar sistemáticamente a los usuarios por rutas alternativas.

Fuentes de sesgo y consecuencias

Los sesgos provienen de 2 fuentes: las noticias y los reportes. En cuanto a la primera, se preprocesan para eliminar tendencias políticas, y los usuarios que envíen reportes discriminatorios son dados de baja.

Compromisos de diseño a favor de la equidad

Para garantizar la equidad, se emplea Aleatoriedad Controlada en las rutas con seguridad similar y el Reciclaje de Zonas para que el riesgo disminuya si no hay nuevos incidentes. Además, se utiliza la Normalización por Densidad Poblacional (tasa relativa de crimen) para penalizar menos las zonas turísticas, y el Comité Ético realiza una Supervisión Continua para auditar sesgos.

Métricas de equidad y límites auto-impuestos

Las métricas de equidad incluyen la Equal Performance Across Groups (precisión similar entre poblaciones) , el False Positive / False Negative Balance (para detectar sobre/subestimación del riesgo) , y el Distributional Coverage (cobertura total de la ciudad en las rutas recomendadas). Los mínimos auto-impuestos se centran en la Transparencia (explicar los datos al usuario) , la Revisión Humana Periódica , el Control de Calidad de Datos (depuración de reportes subjetivos) , y un Mecanismo de Retroalimentación para reportar rutas mal clasificadas.

Limitaciones, dudas abiertas y pasos futuros

Limitaciones conocidas

El sistema presenta actualmente las siguientes limitaciones:

- **Dependencia de los datos:** La calidad de las recomendaciones está intrínsecamente ligada a la calidad y disponibilidad de los datos.
- **Coste computacional y latencia:** Mantener un análisis en tiempo real a gran escala es técnicamente complejo y costoso.
- **Funcionalidad en zonas de baja conectividad:** En áreas con mala cobertura de red, la capacidad del sistema para actualizar rutas dinámicamente se ve comprometida.
- **Riesgo de proyecto:** El ambicioso objetivo de precisión superior al 95% con menos de un 1% de falsos negativos sigue siendo un reto técnico fundamental para el proyecto.

Pasos futuros

Nuestros esfuerzos futuros se centrarán en:

- **Profundizar en la IA explicable (XAI):** Seguiremos investigando e implementando técnicas avanzadas de XAI para hacer el modelo aún más transparente y auditable.
- **Expandir las fuentes de datos:** Buscaremos activamente nuevas fuentes para enriquecer el modelo y reducir aún más los sesgos.
- **Establecer colaboraciones estratégicas:** Planeamos colaborar con ayuntamientos y organizaciones comunitarias para que los datos agregados de GPS-Safe sirvan como un mecanismo de retroalimentación para **dialogar y mejorar la seguridad real en las zonas desfavorecidas**.

Nuestro compromiso es con la creación de entornos urbanos más seguros a través de una tecnología responsable. GPS-Safe no es solo un producto, sino una declaración de que el desarrollo tecnológico debe estar, ante todo, centrado en el ser humano.

En caso de querer ahondar en los apartados de la Model Card, se han definido una serie de Anexos donde se trata cada punto de manera más técnica y/o rigurosa. A continuación el listado con los links al repositorio:

- ANEXO 1.Casos de uso previstos y no previstos
- ANEXO 2: Datos y Entrenamiento del sistema
- ANEXO 3: Evaluación y métricas
- ANEXO 4: Privacidad y protección de datos
- ANEXO 5: Propiedad intelectual y modelo de apertura
- ANEXO 6: Marco de Riesgos, Límites Operacionales y Gobernanza
- ANEXO 7: Usuarios, sesgos y colectivos afectados